

Project Report

CSW 439

Nhóm 1



Introduction & Data Cleaning

Logistic Regression

Decision Tree

Random Forest

KNN

Comparison

● Nhóm 1

1. Tiền xử lý dữ liệu (Data Preprocessing)

Nền tảng xây dựng mô hình phân loại đánh giá khách hàng

Mục tiêu cốt lõi

Làm sạch, hiểu và hợp nhất dữ liệu từ nhiều nguồn khác nhau nhằm chuẩn bị dữ liệu đầu vào có chất lượng tốt nhất cho việc huấn luyện mô hình.

Sơ đồ quy trình tổng quan (Pipeline) >

1.
Load,
Đọc dữ
liệu thô

2.
Understand
Khám phá
& Đánh giá

3.
Aggregation
Trích xuất &
Tổng hợp

4.
Merge &
Dedup
Hợp nhất &
Làm sạch

5.
Perfor-
mance
Measure-
ment

Nhóm 1

2. Khám phá cấu trúc dữ liệu

Olist Brazilian E-Commerce - 6 Tập dữ liệu gốc

Reviews

- 99.224 dòng
- 7 cột
- Điểm số đánh giá, tiêu đề, text



Orders

- 99.441 dòng
- 8 cột
- Trạng thái, mốc thời gian



Products

- 32.951 dòng
- 9 cột
- Kích thước, khối lượng, số ảnh



Order Items

- 112.650 dòng
- 7 cột
- Mã sản phẩm, giá bán, phí vận chuyển



Payments

- 103.886 dòng
- 5 cột
- Hình thức thanh toán, số kỳ, giá trị



Customers

- 99.441 dòng
- 5 cột, Thông vị trí, ID khách hàng



Nhóm 1

3.Đánh giá chất lượng dữ liệu đầu vào Data Quality Assessment

1. Dữ liệu trùng lặp (Duplicates)

Hoàn hảo: Phát hiện 0 dòng trùng lặp ở cả 6 bảng dữ liệu gốc.

2. Giá trị khuyết thiếu (Missing Values)

Bảng Orders

Thiếu ngày giao hàng thực tế: 2.965 dòng

Thiếu ngày chuyển hàng: 1.783 dòng

Ảnh hưởng trực tiếp đến việc tính toán đặc trưng thời gian giao hàng.

Bảng Reviews

Tỷ lệ khuyết thiếu văn bản rất cao:


Tiêu đề thiếu 88%, Bình luận thiếu 59%.

Bảng Products

Thiếu mô tả, danh mục và ảnh đối với 610 mã sản phẩm.

4. Khởi tạo bảng dữ liệu cơ sở Base DataFrame Creation

Chiến lược: Lấy bảng Reviews làm trọng tâm



Kết quả khởi tạo:
Thu được Base DataFrame ban đầu gồm 98.673 dòng và 18 cột thuộc tính.

Nhóm 1

5. Trích xuất đặc trưng tài chính & Vận chuyển Item & Payment Aggregations

Vấn đề: Một đơn hàng (order_id) có thể chứa nhiều mặt hàng và thanh toán qua nhiều lần
→ Cần gom nhóm thành tỷ lệ 1-1.

1. Tổng hợp mặt hàng

- Tổng giá trị hàng hóa - total_price
- Tổng chi phí vận chuyển - freight_value

2. Tổng hợp thanh toán

- Tổng số tiền đã thanh toán - payment_value
- Trung bình số kỳ trả góp - payment_installments
- Phương thức thanh toán chủ đạo - payment_type (Mode)

6.Trích xuất đặc trưng vật lý sản phẩm

Product Aggregations

1. Liên kết dữ liệu

Thực hiện Left Merge bảng chi tiết đơn hàng với thông tin sản phẩm.

2. Kiến tạo đặc trưng mới

Tính toán thể tích vật lý cho từng sản phẩm:

$$\text{Volume (cm}^3\text{)} = \text{Length} \times \text{Height} \times \text{Width}$$

Tổng hợp theo đơn hàng

```
.groupby('order_id').mean()
```

Khối lượngTB

product_weight_g

Số lượng ảnhTB

product_photos_qty

Độ dài mô tảTB

product_description_lenght

Thể tích trung bình

product_volume

7. Hợp nhất toàn diện & Kết quả Final Merge & Deduplication

1. Hợp nhất cuối cùng

Ghép Base DataFrame với 3 nhóm thuộc tính vừa trích xuất thông qua khóa chung order_id.

2. Làm sạch trùng lặp

Sử dụng drop_duplicates() loại bỏ toàn bộ đơn hàng lặp để tránh nhiễu mô hình.

Kết Quả Tiền Xử Lý Sẵn Sàng

Kích thước dữ liệu

94.504 Dòng

Sau drop NaN từ
98.673 dòng gốc

Số features

14

Chọn lọc từ 27 thuộc tính
gốc của 6 bảng

Train Set (80%)

75.603 Mẫu

Stratified split
random_state = 42

Test Set (20%)

18.901 Mẫu

Dùng đánh giá
hiệu suất mô hình

Logistic Regression

Nhóm 1

Nguyên lý hoạt động

Phương trình tuyến tính: dựa trên các đặc trưng đầu vào (x), trọng số (w) và độ lệch chuẩn (b):

$$z = w^T x + b$$

Hàm Sigmoid:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$



Nhóm 1

Chuẩn hóa dữ liệu

Ví dụ:

- Nhà 1: 50m², 1 phòng ngủ.
- Nhà 2: 100m², 2 phòng ngủ.
- Nhà 3: 150m², 3 phòng ngủ.

Cột “Diện tích”:

Dữ liệu gốc (X): [50, 100, 150]

Cột “Phòng ngủ”:

Dữ liệu gốc (X): [1, 2, 3]



Cột “Diện tích”:


Sau chuẩn hóa: [-1.22, 0, 1.22]

Cột “Phòng ngủ”:

Dữ liệu gốc (X): [-1.22, 0, 1.22]

Nhóm 1

Huấn luyện model




$$z = w^T x + b$$

Nhóm 1

Kết quả


Classification Report:			
	precision	recall	f1-score
Negative (0)	0.40	0.42	0.41
Positive (1)	0.84	0.83	0.84



Nhóm 1

Tối ưu: SMOTE + threshold tuning

	precision	recall	f1-score	support
Negative (0)	0.32	0.57	0.41	3976
Positive (1)	0.85	0.67	0.75	14925



Kết luận

- Vấn đề ban đầu: Mô hình đạt độ chính xác (Accuracy) khá cao (**74.5%**), nhưng bị ảnh hưởng bởi dữ liệu mất cân bằng (nhóm "Vui vẻ" chiếm đa số).
- Việc nhận diện nhóm khách hàng "Tức giận" (Recall Nhãn 0) bị hạn chế, ban đầu chỉ đạt 42%.
- Phương pháp tối ưu: Áp dụng kỹ thuật sinh dữ liệu SMOTE kết hợp tinh chỉnh ngưỡng Threshold Tuning (**0.55**) để tập trung giải quyết bài toán thực tế của dự án.
- Kết quả đạt được: Tỷ lệ Recall Nhãn 0 đã tăng đáng kể từ **42%** lên **57%**, giúp doanh nghiệp giảm thiểu tối đa rủi ro bỏ lọt các trải nghiệm tồi tệ của khách hàng.

Decision Tree Model

Principles of Decision Tree


Rule-based Learning:

Mô hình phân tách dữ liệu qua các nút điều kiện để tạo ra các nhóm đồng nhất.

- Tính minh bạch cao: Quy tắc rõ ràng, trực quan, dễ giải thích lý do đằng sau mỗi dự đoán
- Ít tiền xử lý: Không yêu cầu phải chuẩn hóa (scaling) hay biến đổi dữ liệu phức tạp trước khi train.
- Xử lý lệch lớp: Dùng tham số `class_weight='balanced'` để tự động tăng trọng số phạt khi dự đoán sai lớp thiểu số (Negative reviews).

Decision Tree

A decision tree is a flowchart-like model used for classification and regression. It splits data based on features to make predictions. It looks like:



Nhóm 1

Data Preprocessing & Feature Engineering



Đặc trưng Vận hành (Operational)

Trích xuất từ lịch sử giao hàng: số ngày giao thực tế (delivery_days), số ngày bị trễ (delay_days).




Đặc trưng Kỹ thuật (Engineered)

Phân tích áp lực tài chính & vật lý: Tỷ lệ phí ship trên giá trị (freight_ratio), phương thức thanh toán, thể tích hàng (product_volume).



Quy trình Phát triển (Pipeline)

Train (huấn luyện trên dữ liệu cũ) → Predict (dự đoán trên tập test)
→ Evaluate (đánh giá hiệu năng).




● Nhóm 1

Decision Tree Performance (Baseline)

Performance Metric	Value
Accuracy	0.735570
Precision	0.850604
Recall	0.806834
F1-score	0.828141

- Model đạt Precision và Recall ở mức khá, cho thấy khả năng dự đoán lớp Positive tốt.
- Tuy nhiên, Confusion matrix cho thấy vẫn còn nhầm một phần mẫu Negative sang Positive.
- Do dữ liệu có xu hướng lệch lớp, Accuracy chỉ nên đọc cùng Precision, Recall và F1-score để có cái nhìn toàn diện.




Nhóm 1

Tối ưu phát hiện đánh giá Xấu bằng Decision Tree

Selected threshold_good: 0.5

	Metric	Baseline	Optimized
	Accuracy	0.735570	0.608328
	Recall (Bad)	0.468058	0.635563
	Precision (Bad)	0.392285	0.297960
	F1 (Bad)	0.426835	0.405716

- Chia train thành fit/validation theo stratify.
- Tìm cấu hình Decision Tree tốt nhất thỏa Recall (Bad) ≥ 0.55 .
- Tìm threshold dự đoán tốt nhất (trong nhóm thỏa recall) để tối đa Accuracy.



Conclusion & Insights

Decision Tree đóng vai trò là Baseline Model cung cấp logic phân loại trực quan. Ở phiên bản tối ưu, mô hình được điều chỉnh để ưu tiên phát hiện mẫu Negative, giúp Recall (Bad) tăng từ 0.468 lên 0.636 nhưng Accuracy giảm từ 0.736 xuống 0.608. Vì vậy, đánh giá hiệu năng cần ưu tiên Recall và Confusion Matrix thay vì chỉ dựa vào Accuracy.


Random Forest Model

Nguyên Lý Hoạt Động Của Random Forest

Học Nhóm (Ensemble Learning)

Xây dựng dựa trên sự kết hợp của nhiều Cây quyết định (Decision Trees). Kết quả cuối cùng là sự biểu quyết đa số từ các cây.

- Bootstrap Aggregation (Bagging): Huấn luyện trên các tập dữ liệu con ngẫu nhiên giúp giảm hiện tượng quá khớp (overfitting).
- Feature Randomness: Tại mỗi nút phân nhánh, chỉ xem xét một nhóm ngẫu nhiên các đặc trưng để tránh sự trùng lặp giữa các cây.
- Xử lý Mất cân bằng: Dùng `class_weight='balanced'` tự động tăng trọng số hình phạt cho lớp thiểu số (đánh giá xấu).



Tiền Xử Lý Dữ Liệu & Kỹ Nghệ Đặc Trưng (Feature Engineering)



Đặc Trưng Vận Hành

Các chỉ số cốt lõi từ dữ liệu giao hàng:

- `delivery_days`: Số ngày giao thực tế
- `delay_days`: Số ngày trễ thực tế
- `product_volume`: Thể tích sản phẩm



Đặc Trưng Mở Rộng

Khai thác khía cạnh tài chính:

- `freight_ratio`: Tỷ lệ Phí ship / Giá trị SP (Áp lực tài chính).
- `payment_type`: Phương thức thanh toán chính.



Luồng Xử Lý Cốt Lõi


Quy trình triển khai mô hình:

- `Train`: Huấn luyện trên tập lịch sử.
- `Predict`: Dự đoán trên tập dữ liệu mới.
- `Evaluate`: Đánh giá hiệu năng thực tế.

Mô Hình Mặc Định (Ngưỡng 0.5)

Random Forest (baseline)

	precision	recall	f1-score	support
Negative (0)	0.73	0.22	0.34	3976
Positive (1)	0.83	0.98	0.90	14925
accuracy			0.82	18901
macro avg	0.78	0.60	0.62	18901
weighted avg	0.81	0.82	0.78	18901




Tối Ưu Hóa Bằng Phương Pháp Điều Chỉnh Ngưỡng (Threshold Tuning)

Random Forest (undersampling + threshold 0.6)

	precision	recall	f1-score	support
Negative (0)	0.27	0.73	0.39	3976
Positive (1)	0.87	0.46	0.60	14925
accuracy			0.52	18901
macro avg	0.57	0.60	0.50	18901
weighted avg	0.74	0.52	0.56	18901

Balanced Random Forest Confusion Matrix (Threshold = 0.60)



Threshold Tuning

Giải pháp: Sử dụng `predict_proba()`. Hạ mức tin cậy của việc dự đoán "Hài lòng" xuống ngưỡng 0.65 (Chỉ đoán khách hài lòng nếu độ tự tin $> 65\%$, ngược lại xếp vào nhóm có nguy cơ).

Metric	Threshold 0.5	Threshold 0.6
Accuracy	67.25%	52.02%
Correct Negative Predictions	2.198	2.912
Missed Negative Reviews	1.778	1.064
False Warnings	4.413	8.005
Negative Recall	55.28%	73.24%

Kết luận


Bằng cách áp dụng kỹ thuật giảm mẫu ngẫu nhiên (Undersampling) kết hợp điều chỉnh ngưỡng quyết định về 0.6, mô hình Balanced Random Forest đã cải thiện vượt bậc hiệu quả phát hiện rủi ro từ khách hàng không hài lòng. Mô hình nhận diện chính xác đến 2.912 đánh giá tiêu cực (độ nhạy lớp tiêu cực đạt 73.24%) và chỉ còn bỏ sót 1.064 trường hợp. Mặc dù việc tối ưu hóa này làm giảm độ chính xác tổng thể xuống 52.02% và tăng số lượng cảnh báo nhầm (False Warnings) lên 8.005, đây vẫn là giải pháp thực tế hơn để doanh nghiệp chủ động chăm sóc khách hàng và giảm thiểu rủi ro rời bỏ.

KNN Model

Olist Review Prediction

k-nearest neighbor

What is KNN?



 Nhóm 1


Training the Model

$n = 15$

weights = distance

☒ Nhóm 1

Training the Model




 Nhóm 1

Training the Model

75,603
Training orders

18,901
Training orders




☒ Nhóm 1

Training the Model

Source	Negative 0	Positive 1
Training actual labels	21.1%	78.9%
KNN predictions	6.9%	93.1%


 Nhóm 1

Result



Nhóm 1

Result



Kết hợp với SMOTE + Threshold 0.45

2399 review xấu được dự đoán đúng.

1577 review xấu bị dự đoán nhầm thành review tốt.

6317 review tốt bị cảnh báo nhầm thành review xấu.

8608 review tốt được dự đoán đúng.

Conclusion


Kết luận KNN (sau cải thiện)

Baseline (k=5): model đạt accuracy ~81.79%, dự đoán đúng phần lớn test set. Nhưng recall class 0 chỉ ~23.21% — bỏ sót gần 77% review xấu, vì KNN bị thiên về class đa số (Positive) trên dữ liệu mất cân bằng.

So sánh tổng hợp các mô hình

	model	accuracy	precision_neg0	recall_neg0	f1_neg0	f1_weighted
0	Decision Tree (baseline)	0.7356	0.3923	0.4681	0.4268	0.7437
1	Decision Tree (optimized)	0.6083	0.2980	0.6356	0.4057	0.6443
2	KNN baseline (k=5)	0.7947	0.5250	0.2538	0.3421	0.7656
3	KNN (SMOTE k=15 + threshold 0.45)	0.5824	0.2752	0.6034	0.3780	0.6209
4	Logistic Regression (baseline)	0.7450	0.3997	0.4230	0.4110	0.7476
5	Logistic Regression (SMOTE + threshold 0.55)	0.6493	0.3155	0.5707	0.4064	0.6786
6	Random Forest (baseline)	0.8193	0.7286	0.2248	0.3436	0.7792
7	Random Forest (undersampling + threshold 0.6)	0.5202	0.2667	0.7324	0.3911	0.5593

So sánh tổng hợp các mô hình



Kết luận

Tất cả 4 mô hình dùng chung 14 features và cùng tập train/test. Kết quả cho thấy một sự đánh đổi rõ ràng giữa Accuracy/Precision và Recall của class 0 (review xấu) — đúng với bản chất bài toán cảnh báo sớm trên dữ liệu mất cân bằng.

- Accuracy / Precision cao nhất (ít báo động giả): Random Forest (baseline) mạnh nhất — accuracy ≈ 0.82 , precision class 0 ≈ 0.73 . Nhưng recall class 0 chỉ ≈ 0.22 , tức bỏ sót gần 78% review xấu.
- Bắt được nhiều review xấu nhất (Recall class 0): Random Forest (undersampling + threshold 0.60) đạt recall ≈ 0.73 , cao nhất toàn bộ, đổi lại accuracy giảm còn ≈ 0.52 . Hai lựa chọn cân bằng hơn: Decision Tree (optimized) recall ≈ 0.64 (acc ≈ 0.61) và KNN (SMOTE + threshold) recall ≈ 0.60 (acc ≈ 0.58).
- Cân bằng tốt nhất (F1 class 0): các baseline đơn giản lại cho F1 class 0 tốt nhất — Decision Tree baseline ≈ 0.43 , Logistic Regression baseline ≈ 0.41 .

•


Question

Tại sao KHÔNG cần chuẩn hóa dữ liệu cho Decision Tree & Random Forest ?

- Chia theo ngưỡng (Thresholds): Thuật toán chỉ tìm điểm cắt trên từng biến độc lập (VD: Tuổi > 30), không gộp chung các biến lại với nhau.
- Không đo khoảng cách: Quyết định dựa trên logic phân nhánh (If-Else), hoàn toàn bỏ qua khoảng cách không gian hình học.
- Bất chấp thang đo Sự chênh lệch đơn vị lớn (Triệu VNĐ vs Ngày) không ảnh hưởng đến cấu trúc cây phân lớp.

 Nhóm 1

Mức độ đóng góp của từng thành viên



- Trần Quốc An — 22%
Train model, làm slide, thuyết trình
- Lê Minh Trí — 22%
Train model, làm slide, thuyết trình
- Nguyễn Phúc Hậu — 22%
Train model, làm slide, thuyết trình
- Đặng Cao Cường — 22%
Train model, làm slide, thuyết trình
- Lê Triết Huân — 12%
Xử lý data

thank you